

Проект «Анализ рынка недвижимости»

Часть 1. Исследовательский анализ данных

На данном этапе проводится оценка объёма данных, разброс метрик и поиск ошибок вроде аномальных или неправдоподобных значений.

1.1 Временной интервал

Данные представлены с конца ноября 2014 года по начало мая 2019 года.

1.2 Типы населённых пунктов

- данные содержат информацию о 10 типах населённых пунктов;
- большая часть объявлений (20 008 или около 85% всех объявлений) содержит информацию о недвижимости в городах;
- садоводческое некоммерческое товарищество содержит всего одно объявление.

1.3 Время активности объявления

Основные статистики по полю со временем активности объявлений:

- минимум: 1 день;
- максимум: 1580 дней ($\approx 4,33$ года);
- среднее: 180,75 дня;
- медиана: 95 дней.

Медиана отличается от среднего значения, что может говорить о наличии единичных высоких значений — выбросов. Результаты показывают, что половину объявлений сняли с публикации в течение 95 дней с момента публикации.

1.4 Доля снятых с публикации объявлений

Доля снятых с публикации объявлений достигает 86,55 %. Если интерпретировать снятие с публикации как признак продажи, то массив данных можно считать репрезентативным для изучения рынка.

1.5 Объявления Санкт-Петербурга

В Санкт-Петербурге размещено 66,47 % всех объектов недвижимости, выставленных на продажу.

Соотношение между объявлениями в Санкт-Петербурге и Ленинградской области — примерно 2 к 1. Такое соотношение позволяет изучить объявления в двух субъектах отдельно и сопоставить результаты между собой, хоть и объявлений в Санкт-Петербурге почти в два раза больше.

1.6 Стоимость квадратного метра

- минимум: 111,83 руб/м²;
- максимум: 1907500,00 руб/м²;
- среднее: 99432,25 руб/м²;
- медиана: 95000,00 руб/м².

Среднее близко к медиане — это может указывать либо на отсутствие выбросов, либо на их симметричное распределение. При этом в данных есть экстремальные значения: от 112 до 1 907 500 руб/м². Низкое значение, вероятно, ошибка (например, указано в тысячах), а высокое — аномалия. Для общего анализа такие выбросы стоит исключить, чтобы не исказить картину рынка.

1.7 Проверка признаков на аномальные значения

Данные содержат аномально высокие значения практически в каждом столбце, кроме этажа недвижимости.